

بسمه تعالی

آرمان صالحی

40113421

دانشکده ریاضیات و علوم کامپیوتر

درس رگرسیون خطی

دکتر قطاری

پاییز 1404

مقدمه

در این پروژه هدف اصلی ما بررسی و تحلیل عواملی است که میتوانند بر عملکرد تحصیلی دانشجویان در یک درس تاثیرگذار باشند. همیشه این سوال وجود دارد که آیا صرفاً افزایش ساعات مطالعه تضمین کننده نمره بهتر است یا عوامل دیگری مثل نحوه تدریس نیز نقش دارند؟ برای بررسی این موارد از یک دیتاست به نام `students_performance.csv` استفاده کردیم که اطلاعات ۱۲۰ دانشجو را شامل میشود. این داده‌ها شامل چهار ستون اصلی هستند: شناسه دانشجو، میزان ساعات مطالعه در هفته، نمره نهایی امتحان و مدت آموزشی که در کلاس مورد استفاده است.


حال ابتدا با استفاده از تحلیل اکتشافی داده‌ها (EDA) و رسم نمودارها، سعی کردیم تا یک دید جامع نسبت به وضعیت توزیع نمرات و رابطه بین متغیرهای موجود پیدا کنیم. پس از اطمینان از وجود یک رابطه خطی، از مدل رگرسیون خطی ساده استفاده کردیم تا بتوانیم نمره امتحان را بر اساس ساعات مطالعه پیشبینی کنیم و توان این مدل را با معیار R^2 بسنجیم.

اما دغدغه دیگر ما بررسی عدالت آموزشی است. به همین دلیل، با استفاده از آزمون ANOVA بررسی میکنیم که آیا روش‌های مختلف تدریس تأثیری بر میانگین نمرات دانشجویان دارند یا خیر. همچنین برای ارزیابی کلی وضعیت کلاس، با یک آزمون T-Test تک‌نمونه‌ای، میانگین نمرات کلاس را با حد نصاب مورد قبول مقایسه کردیم.

در نهایت، برای درک محدودیت‌های مدل‌سازی بحث برون‌یابی را مطرح کردیم تا نشان دهیم که استفاده از مدل‌های رگرسیونی در مقادیر خارج از دامنه بسیار خطرناک و شامل خطا میباشد. تمام مراحل کدنویسی و محاسبات در فایل نوت‌بوک پیوست شده است.

تحلیل رگرسیون

پس از آشنایی اولیه با داده‌ها، در گام نخست به سراغ بررسی بصری رفتیم. رسم نمودار Scatter Plot به وضوح نشان داد که یک رابطه مستقیم و قوی میان ساعات مطالعه و نمره امتحان وجود دارد؛ به طوری که با افزایش ساعت مطالعه، نمرات نیز با یک شیب نسبتاً ثابت بالا می‌روند. این مشاهده بصری، ما را مطمئن کرد که استفاده از یک مدل "رگرسیون خطی ساده" انتخاب درستی برای این مسئله است.



با Fit کردن مدل بر روی داده‌ها، به نتایج دقیقی رسیدیم. معادله به‌دست‌آمده نشان داد که عرض از مبدأ حدود ۴۲.۴۳ و شیب خط برابر با ۲.۸۲ است. این یعنی اگر دانشجویی هیچ مطالعه‌ای نداشته باشد نمره‌ای در حدود ۴۲ کسب میکند و شیب خط نشان می‌دهد که به طور متوسط هر یک ساعت مطالعه اضافی در هفته نمره نهایی دانشجو را حدود ۲.۸ افزایش میدهد.


برای بررسی قابل اعتماد بودن این مدل، ضریب تعیین را مشخص میکنیم که برابر با ۰.۷۰۴ است. یعنی این مدل توانسته حدود ۷۰ درصد از تفاوت نمرات دانشجویان را صرفاً با استفاده از "ساعت مطالعه" توضیح دهد. ۳۰ درصد باقی‌مانده مربوط به عوامل دیگری است که در این مدل بررسی نشده است. در پایان این بخش، برای اطمینان نهایی، نمودار Residuals را هم چک کردیم. از آنجایی که خطاها الگوی خاصی نداشتند و به صورت تصادفی پخش شده بودند، مطمئن شدیم که فرضیات مدل خطی رعایت شده و نتایج ما از اعتبار آماری کافی برخوردارند.

	study_hours	actual_score	fitted_score	residuals
0	11.5	79.2	74.893422	4.306578
1	9.6	70.0	69.530172	0.469828
2	11.9	77.3	76.022527	1.277473
3	14.6	90.5	83.643988	6.856012
4	9.3	67.0	68.683343	-1.683343

تحلیل تأثیر روش تدریس و وضعیت کلی کلاس (ANOVA & T-Test)

آیا دانشجویانی که با متدهای مختلف آموزش دیده‌اند، نمرات متفاوتی گرفته‌اند؟ یا اینکه شیوه تدریس در این دیتاست عملاً تاثیری نداشته است؟

برای پاسخ به این سوال، ابتدا به سراغ بصری سازی رفتیم. رسم نمودارهای جعبه‌ای و ویولن یک دید کلی به من داد. چیزی که در نمودارها دیدم جالب بود، توزیع نمرات در هر سه گروه تقریباً همپوشانی داشت و تفاوت چشمگیری در میانگین‌ها دیده نمیشد. اما برای اینکه حرفم علمی باشد، از آزمون آماری ANOVA استفاده کردم



نتیجه آزمون آماری دقیقاً مشاهدات بصری من را تایید کرد. مقدار P-value به دست آمده حدود 0.98 بود. در دنیای آمار، این عدد یعنی ما هیچ دلیل موجهی نداریم که بگوییم میانگین نمرات این سه گروه با هم فرق دارد. به عبارت ساده‌تر، در این کلاس خاص، نوع متد تدریس تاثیر معناداری روی نمره نهایی بچه‌ها نداشته است و شانس موفقیت در هر سه گروه یکسان بوده

در مرحله آخر تحلیل آماری، می‌خواستم یک ارزیابی کلی از وضعیت علمی کلاس داشته باشم. سوال این بود: آیا میانگین نمرات کل کلاس، به طور معناداری از نمره قبولی بالاتر است؟ برای این کار از آزمون T-Test استفاده کردم. خروجی این آزمون بسیار قاطع بود. با توجه به مثبت بودن آماره t و مقدار P-value که نزدیک به صفر بود، با اطمینان ۹۵ درصد میتوانیم بگوییم که بله، میانگین جامعه آماری دانشجویان این درس، قطعاً بالاتر از ۶۰ است و وضعیت عمومی کلاس مطلوب ارزیابی میشود

خطرات برون یابی

یکی از جذاب‌ترین بخش‌های این پروژه، آزمایش محدودیت‌های مدل بود. ما یک مدل خطی خوب داشتیم که برای داده‌های موجود عالی کار میکرد. اما سوال این بود که آیا میتوانیم از این مدل برای هر شرایطی استفاده کنیم؟

برای پاسخ به این سوال، یک آزمایش برون یابی انجام دادم. از مدل خواستم نمره دانشجویی را پیش‌بینی کند که ۴۰ ساعت در هفته درس میخواند، نتیجه شگفت‌انگیز بود مدل نمره‌ای بالای ۱۰۰ پیش‌بینی کرد. این نتیجه به وضوح نشان داد که اعتماد به مدل‌های رگرسیونی در خارج از بازه داده‌های مشاهده شده، چقدر میتواند خطرناک باشد. واقعیت این است که رابطه "تلاش-نمره" تا ابد خطی نمیماند؛ در دنیای واقعی نمره سقف دارد و همچنین یعنی از یک جایی به بعد، مطالعه بیشتر تاثیر کمتری دارد. این بخش به من یاد داد که هر مدل آماری، فقط در دامنه خودش پاسخگو است و خارج از آن میتواند نتایج بی معنی تولید کند

نتیجه گیری

در مجموع، این پروژه دید بسیار روشنی نسبت به عوامل موثر بر نمرات به ما داد. تحلیل‌ها نشان داد که:

1. **تلاش مهم‌ترین فاکتور است:** ساعات مطالعه رابطه مستقیم، خطی و قدرتمندی با نمره دارد
 2. **روش تدریس تعیین‌کننده نیست:** هیچ شواهد آماری مبنی بر برتری یکی از متدها بر دیگری پیدا نشد
 3. **وضعیت کلاس مطلوب است:** میانگین نمرات به طور معناداری بالاتر از حد نصاب قبولی است
 4. **مدل‌ها محدودیت دارند:** نباید از مدل‌های خطی ساده برای پیش‌بینی‌های دور از دسترس (برون‌یابی) استفاده کرد، زیرا واقعیت‌های فیزیکی (مثل سقف نمره) را نادیده می‌گیرند.
- این تحلیل نشان می‌دهد که برای بهبود نمرات در این درس خاص، تمرکز روی افزایش ساعت مطالعه دانشجویان استراتژی درستی است، اما نباید انتظار داشت که تغییر روش تدریس به تنهایی معجزه کند