




دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

دانشکده ریاضیات و علوم کامپیوتر

تشخیص و بهبود مدل رگرسیون خطی چند متغیره

پروژه دوم درس رگرسیون

آرمان صالحی

استاد درس:

دکتر امیرحسین قطاری

زمستان ۱۴۰۴



چکیده

در این پروژه قصد داشتیم با استفاده از رگرسیون خطی چندگانه، رفتار متغیر وابسته را بر اساس پنج متغیر مستقل پیشبینی کنیم. وقتی مدل اولیه را روی داده ها پیاده کردیم، متوجه شدیم که نتیجه چندان راضی کننده نیست؛ مدل تنها حدود ۳۵ درصد از تغییرات را توضیح میدهد و بررسی نمودارها نشان داد که خطاهای مدل اصلاً نرمال نیستند. با دقیق تر شدن در داده ها فهمیدیم که مشکل اصلی بدلیل تعدادی داده پرت و نادیده گرفتن تعامل بین متغیرها است، بنابراین تصمیم گرفتیم مدل را اصلاح کنیم. با حذف داده های مزاحم و اضافه کردن یک ترم تعاملی بین متغیرهای سوم و پنجم، وضعیت مدل به کلی تغییر کرد. در نهایت، دقت مدل یا همان R^2 تقریباً دو برابر شد و به ۶۳ درصد رسید و مهمتر از همه اینکه تمام تست های آماری تایید کردند که مشکلات قبلی حل شده و حالا میتوان با اطمینان کامل به نتایج این مدل اعتماد کرد.



فهرست مطالب

بخش اول: معرفی داده و مسئله آماری	۴
بخش دوم: توضیح مدل رگرسیون چند متغیره	۴
بخش سوم: تفسیر ضرایب و آزمون های آمار	۶
بخش چهارم: تحلیل فروض مدل و پیامدهای نقض آن ها	۷
بخش پنجم: توضیح فرآیند انتخاب مدل و دلیل انتخاب مدل نهایی	۹
بخش ششم: جمع بندی و نتیجه گیری	۱۱



بخش اول: معرفی داده و مسئله آماری

هدف اصلی این پژوهش، مدل سازی رابطه بین یک متغیر وابسته (y) و پنج متغیر مستقل (x_1 تا x_5) با استفاده از رگرسیون خطی چندگانه است. مجموعه داده مورد بررسی شامل ۲۶۰ مشاهده می باشد. پیش از برآزش مدل، تحلیل اکتشافی داده ها نشان داد که متغیر وابسته در طول زمان نوسانات منظمی دارد و همبستگی های اولیه میان متغیرهای مستقل و وابسته وجود دارد.

مسئله آماری در اینجا، یافتن بهترین ترکیب خطی از متغیرهای مستقل است که بتواند واریانس متغیر y را توضیح دهد، ضمن اینکه فروض کلاسیک رگرسیون (مانند نرمال بودن خطاها و ثبات واریانس) نیز برقرار باشند. همچنین شناسایی مشاهدات پرت که ممکن است برآوردها را دچار اریب کنند، بخشی از مسئله است.


بخش دوم: توضیح مدل رگرسیون چند متغیره

مدل رگرسیون خطی چند متغیره روشی است که رابطه بین یک متغیر پاسخ و چندین متغیر مستقل را به صورت خطی مدل میکند. فرم کلی مدل اولیه برآزش شده به صورت زیر است:


$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \epsilon_i$$

که در آن:

- β_0 : عرض از مبدأ
 - β_1 تا β_5 : ضرایب رگرسیون (نشان دهنده میزان تغییر در به ازای یک واحد تغییر در با فرض ثابت بودن سایر متغیرها)
 - ϵ_i : جمله خطا که فرض می شود دارای توزیع نرمال با میانگین صفر و واریانس ثابت است
- در این پژوهش از روش حداقل مربعات معمولی (OLS) برای برآورد ضرایب استفاده شده است که مجموع مربعات خطاها را کمینه میکند.



شکل ۱-الف: تغییرات متغیر پاسخ y در طول زمان



شکل ۱-ب: نمودار Heatmap همبستگی میان متغیرهای مستقل و وابسته



بخش سوم: تفسیر ضرایب و آزمون های آمار

پس از برازش مدل اولیه، نتایج زیر حاصل شد:

- ضریب تعیین: مقدار R^2 برابر با ۰.۳۴۸ به دست آمد. این بدان معناست که مدل پایه تنها قادر است حدود ۳۵ درصد از تغییرات متغیر وابسته را توضیح دهد که مقدار پایینی محسوب میشود.
- آزمون معناداری ضرایب:
 - متغیرهای x_1 و x_2 و x_3 و x_5 همگی دارای P-value کمتر از ۰.۰۵ بودند و از نظر آماری رابطه معناداری با y داشتند.
 - متغیر x_4 با P-value حدود ۰.۷ فاقد معناداری آماری بود. این نشان میدهد که احتمالاً متغیر زائدی است و تاثیری در پیش بینی ندارد.
- آزمون کلی مدل (ANOVA): مقدار آماره F برابر با ۲۷.۱۴ و P-value بسیار نزدیک به صفر بود که نشان میدهد کلیت مدل معنادار است (حداقل یکی از متغیرها موثر است)، اما برازش آن ضعیف میباشد.

OLS Regression Results						
=====						
Dep. Variable:	y	R-squared:	0.348			
Model:	OLS	Adj. R-squared:	0.335			
Method:	Least Squares	F-statistic:	27.14			
Date:	Sun, 08 Feb 2026	Prob (F-statistic):	5.68e-22			
Time:	23:45:07	Log-Likelihood:	-569.92			
No. Observations:	260	AIC:	1152.			
Df Residuals:	254	BIC:	1173.			
Df Model:	5					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	2.9866	0.139	21.442	0.000	2.712	3.261
x1	1.8444	0.401	4.597	0.000	1.054	2.635
x2	-1.2579	0.409	-3.072	0.002	-2.064	-0.451
x3	0.7958	0.218	3.657	0.000	0.367	1.224
x4	0.0802	0.208	0.386	0.700	-0.329	0.489
x5	0.9938	0.117	8.465	0.000	0.763	1.225
=====						
Omnibus:	51.440	Durbin-Watson:	1.676			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	524.991			
Skew:	0.353	Prob(JB):	9.99e-115			
Kurtosis:	9.926	Cond. No.	5.69			
=====						




بخش چهارم: تحلیل فروض مدل و پیامدهای نقض آن ها

برای اطمینان از اعتبار نتایج بالا، فروض کلاسیک رگرسیون مورد آزمون قرار گرفتند:

۱. فرض نرمال بودن خطاها:

نتیجه: آزمون Anderson-Darling و نمودار Q-Q نشان دادند که توزیع باقی مانده ها نرمال نیست ($P\text{-value} < 0.05$). انحراف شدید در دنباله های نمودار Q-Q مشهود بود.

پیامد: نقض این فرض باعث می شود که آزمون های t و فواصل اطمینان ضرایب دقیق نباشند، هرچند برآورد ضرایب همچنان نااریب باقی میماند.




نمودار ۲: نمودار Q-Q برای مدل پایه

۲. فرض همسانی واریانس:

نتیجه: آزمون Breusch-Pagan با $P\text{-value}$ کمتر از ۰.۰۵ نشان داد که واریانس خطاها ثابت نیست.

پیامد: این مشکل باعث میشود خطاهای استاندارد برآورد شده نادرست باشند و در نتیجه آزمون های معناداری ضرایب قابل اعتماد نباشند.



نمودار ۳: نمودار باقی مانده ها در برابر مقادیر برازش شده


۳. فرض هم خطی:

نتیجه: شاخص تورم واریانس برای تمام متغیرها کمتر از ۵ بود.

تفسیر: خوشبختانه مشکل هم خطی شدید بین متغیرهای مستقل وجود ندارد و ضرایب به صورت ناپایدار برآورد نشده اند.

۴. نقاط پرت و اثرگذار:

با استفاده از معیارهای "فاصله کوک" و "باقی مانده های استیودنت"، تعدادی از مشاهدات شناسایی شدند که رفتار متفاوتی با سایر داده ها داشتند و باعث کشیده شدن خط رگرسیون به سمت خود میشدند.





بخش پنجم: توضیح فرآیند انتخاب مدل و دلیل انتخاب مدل نهایی

با توجه به کاستی‌های مدل پایه (نقض فرض نرمالیتی، وجود نقاط پرت و پایین بودن R^2)، اصلاحات زیر به صورت گام به گام انجام شد:

۱. حذف داده‌های پرت: مشاهداتی که توسط شاخص‌های تشخیص (Cook's D و Leverage) پرچم گذاری شده بودند، از تحلیل کنار گذاشته شدند تا از اریب شدن ضرایب جلوگیری شود.
۲. حذف متغیر غیرموثر: متغیر x_4 که در مدل پایه معنادار نبود، حذف گردید تا مدل ساده‌تر شود.
۳. اضافه کردن اثر متقابل: با بررسی روابط بین متغیرها، ترم تعاملی $x_4 \times x_5$ به مدل اضافه شد. فرضیه این بود که اثر متغیر x_3 بر روی y ثابت نیست و به سطح متغیر x_5 بستگی دارد.

نتایج مدل نهایی:


پس از اعمال این تغییرات، مدل جدید برازش شد و بهبودهای زیر حاصل گردید:

- افزایش R^2 : ضریب تعیین از ۰.۳۵ به ۰.۶۳ جهش کرد.
- برقراری فرض نرمالیتی: در مدل جدید، آزمون نرمالیتی مقدار P-value برابر با ۰.۲۳۶ را نشان داد که یعنی فرض نرمال بودن خطاها دیگر رد نمیشود.
- کاهش معیار آکائیک (AIC): مقدار AIC از ۱۱۵۲ به ۸۵۰ کاهش یافت که نشان دهنده برازش بسیار بهتر مدل با داده هاست.



OLS Regression Results						
=====						
Dep. Variable:	y	R-squared:	0.634			
Model:	OLS	Adj. R-squared:	0.626			
Method:	Least Squares	F-statistic:	83.13			
Date:	Sun, 08 Feb 2026	Prob (F-statistic):	2.16e-50			
Time:	23:45:08	Log-Likelihood:	-418.98			
No. Observations:	246	AIC:	850.0			
Df Residuals:	240	BIC:	871.0			
Df Model:	5					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	2.9840	0.088	33.963	0.000	2.811	3.157
x1	1.6527	0.257	6.423	0.000	1.146	2.160
x2	-1.0840	0.265	-4.084	0.000	-1.607	-0.561
x3	0.6397	0.097	6.588	0.000	0.448	0.831
x5	0.8979	0.075	11.903	0.000	0.749	1.046
x3:x5	0.8875	0.087	10.246	0.000	0.717	1.058
=====						
Omnibus:	2.884	Durbin-Watson:	1.361			
Prob(Omnibus):	0.236	Jarque-Bera (JB):	2.194			
Skew:	-0.069	Prob(JB):	0.334			
Kurtosis:	2.559	Cond. No.	5.52			
=====						



نمودار ۴: نمودار Q-Q برای مدل اصلاح شده



بخش ششم: جمع بندی و نتیجه گیری

در این پروژه، فرآیند تشخیص و بهبود مدل رگرسیون خطی طی شد. تحلیل‌ها نشان داد که مدل خطی ساده اولیه به دلیل وجود نقاط پرت و نادیده گرفتن اثرات تعاملی، توانایی توضیح دهنده‌گی پایینی داشت و فروض آماری را نقض میکرد.

با حذف داده‌های مخدوش و اضافه کردن اثر تعاملی $x_3: x_5$ ، مدلی به دست آمد که نه تنها از نظر آماری معتبر است (خطاهای نرمال)، بلکه دقت پیش بینی آن نیز دو برابر مدل اولیه است. این نتیجه نشان میدهد که در این مجموعه داده، رابطه بین متغیرهای مستقل و وابسته صرفاً جمعی نبوده و تعامل بین x_3 و x_5 نقش کلیدی در رفتار سیستم ایفا میکند.

--- Model Comparison Table ---			
	Metric	Baseline	Improved
0	R-squared	0.348188	0.633939
1	Adj. R-squared	0.335357	0.626312
2	AIC	1151.838923	849.955167
3	BIC	1173.203012	870.987156
4	F-statistic	27.136556	83.125550